Actividad 27. Simula una iteración de Q-learning

Aprendizaje Automático · Unidad 4 · Maestría en Inteligencia Artificial · TecNM Virtual
Alumno(a): Nombre Apellido

Entorno (3 estados × 3 acciones)

Estado s	Acción a	Siguiente s'	Recompensa r
S1	Izquierda	S1	-1
S1	Derecha	S2	0
S1	Quedarse	S1	0
S2	Izquierda	S1	0
S2	Derecha	S3	1
S2	Quedarse	S2	0
S3	Izquierda	S2	5
S3	Derecha	S3	-1
S3	Quedarse	S3	3

Parámetros: α = 0.5, γ = 0.9, Q(s,a) = 0 al inicio. Fórmula (ecuación de Bellman aplicada a Q-learning):
Q(s,a) ← Q(s,a) + α · [r + γ · max Q(s',a') − Q(s,a)]

Cálculo paso a paso

Paso	s	a	r	s'	Q ant.	max Q(s',·)	Objetivo	Error TD	Q nuevo
1	S1	Derecha	0	S2	0	0	0	0	0
2	S2	Derecha	1	S3	0	0	1	1	0.5
3	S3	Quedarse	3	S3	0	0	3	3	1.5
4	S3	Izquierda	5	S2	0	0.5	5.45	5.45	2.725
5	S2	Derecha	1	S3	0.5	2.725	3.4525	2.9525	1.9763
6	S3	Izquierda	5	S2	2.725	1.9763	6.7786	4.0536	4.7518

Paso 1: Q(S1,Derecha) = 0.0000 + 0.5·[0 + 0.9·0.0000 − 0.0000] = 0.0000
Paso 2: Q(S2,Derecha) = 0.0000 + 0.5·[1 + 0.9·0.0000 − 0.0000] = 0.5000
Paso 3: Q(S3,Quedarse) = 0.0000 + 0.5·[3 + 0.9·0.0000 − 0.0000] = 1.5000
Paso 4: Q(S3,Izquierda) = 0.0000 + 0.5·[5 + 0.9·0.5000 − 0.0000] = 2.7250
Paso 5: Q(S2,Derecha) = 0.5000 + 0.5·[1 + 0.9·2.7250 − 0.5000] = 1.9763
Paso 6: Q(S3,Izquierda) = 2.7250 + 0.5·[5 + 0.9·1.9763 − 2.7250] = 4.7518

Tabla Q final

Estado	Izquierda	Derecha	Quedarse
S1	0.0000	0.0000	0.0000
S2	0.0000	1.9763	0.0000
S3	4.7518	0.0000	1.5000

Conclusión: ¿qué significa el valor Q más alto?

El valor Q más alto es **Q(S3, Izquierda) = 4.7518**. Significa que, con lo aprendido hasta ahora, la mejor decisión estando en S3 es ir a la izquierda: esa acción da +5 de inmediato y además conduce a S2, un estado desde el cual el agente ya descubrió que puede volver a S3 con recompensa (Q(S2,Derecha) = 1.9763). Es decir, un Q alto resume la **recompensa inmediata más el valor futuro descontado** de elegir esa acción.

Observa que el aprendizaje se **propaga hacia atrás**: en el paso 5, Q(S2,Derecha) saltó de 0.5 a 1.9763 porque el siguiente estado (S3) ya tenía un valor alto (2.725). Con una sola iteración los valores todavía son pequeños y están incompletos (Q(S1,·) sigue en 0); al repetir muchos episodios, Q converge a los valores óptimos de la Actividad 29 (por ejemplo Q*(S3,Izquierda) ≈ 31.05).