Actividad 29. Calcula tu propia tabla Q

Aprendizaje Automático · Unidad 4 · Maestría en Inteligencia Artificial · TecNM Virtual
Alumno(a): Nombre Apellido

Cambio realizado: recompensa de (S3, Quedarse) de +3 a +6. Parámetros: α = 0.5, γ = 0.9.

1) Una iteración (misma trayectoria de la Actividad 27, con +6)

Paso	s	a	r	s'	Q ant.	max Q(s',·)	Objetivo	Error TD	Q nuevo
1	S1	Derecha	0	S2	0	0	0	0	0
2	S2	Derecha	1	S3	0	0	1	1	0.5
3	S3	Quedarse	6	S3	0	0	6	6	3
4	S3	Izquierda	5	S2	0	0.5	5.45	5.45	2.725
5	S2	Derecha	1	S3	0.5	3	3.7	3.2	2.1
6	S3	Izquierda	5	S2	2.725	2.1	6.89	4.165	4.8075

Paso 1: Q(S1,Derecha) = 0.0000 + 0.5·[0 + 0.9·0.0000 − 0.0000] = 0.0000
Paso 2: Q(S2,Derecha) = 0.0000 + 0.5·[1 + 0.9·0.0000 − 0.0000] = 0.5000
Paso 3: Q(S3,Quedarse) = 0.0000 + 0.5·[6 + 0.9·0.0000 − 0.0000] = 3.0000
Paso 4: Q(S3,Izquierda) = 0.0000 + 0.5·[5 + 0.9·0.5000 − 0.0000] = 2.7250
Paso 5: Q(S2,Derecha) = 0.5000 + 0.5·[1 + 0.9·3.0000 − 0.5000] = 2.1000
Paso 6: Q(S3,Izquierda) = 2.7250 + 0.5·[5 + 0.9·2.1000 − 2.7250] = 4.8075

Tabla Q tras una iteración: original (+3) vs. nueva (+6)

Estado	Orig. Izq	Orig. Der	Orig. Quedarse	Nueva Izq	Nueva Der	Nueva Quedarse
S1	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
S2	0.0000	1.9763	0.0000	0.0000	2.1000	0.0000
S3	4.7518	0.0000	1.5000	4.8075	0.0000	3.0000

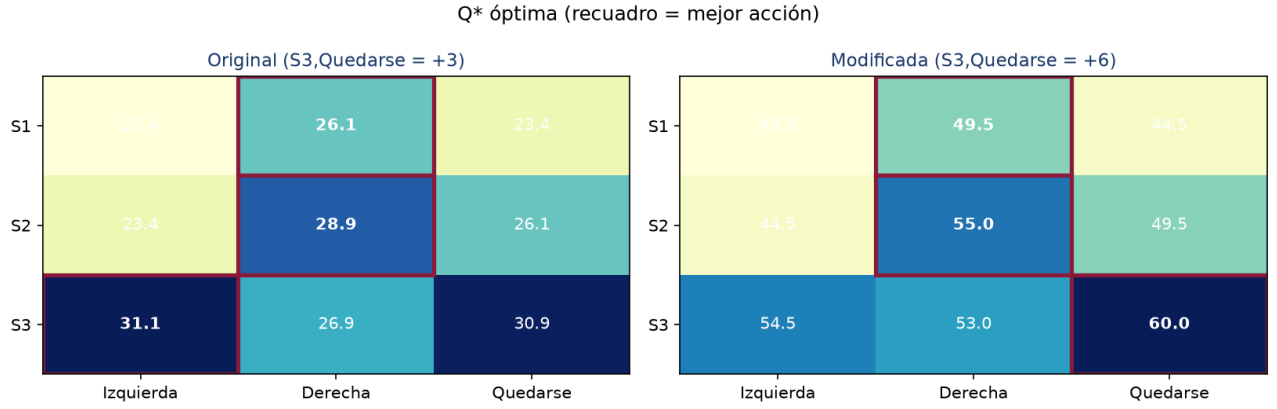
2) Valores óptimos Q* (Bellman iterado hasta converger)

Original (+3)

Estado	Izquierda	Derecha	Quedarse
S1	22.45	26.05	23.45
S2	23.45	28.95	26.05
S3	31.05	26.95	30.95

Nueva (+6)

Estado	Izquierda	Derecha	Quedarse
S1	43.55	49.50	44.55
S2	44.55	55.00	49.50
S3	54.50	53.00	60.00



Análisis

¿Qué cambió en el comportamiento? En S3 la acción óptima pasó de **Izquierda** ($Q^* = 31.05$ frente a 30.95 de Quedarse, casi empatadas) a **Quedarse** ($Q^* = 60$ frente a 54.5). Antes al agente le convenía ir y venir entre S2 y S3 cobrando +5 y +1; ahora se queda en S3 cobrando +6 en cada paso. En S1 y S2 sigue yendo a la derecha, pero todos los valores Q suben porque llegar a S3 vale mucho más.

¿Por qué la nueva recompensa cambió la acción óptima? Porque el valor de una acción es la recompensa inmediata más el valor futuro descontado. Quedarse en S3 produce $6 + 0.9 \cdot V(S3)$, es decir $V(S3) = 6/(1-0.9) = 60$, mientras que el ciclo S3→S2→S3 rinde solo 5.9 por cada dos pasos (≈ 54.5). Al duplicar la recompensa de Quedarse, esa opción supera al ciclo. Tras una sola iteración la tabla todavía no lo refleja del todo, pero con el entrenamiento completo de Q-learning la política converge a la de la solución exacta.