Guía explicativa de las diapositivas

Aprendizaje por Refuerzo · Unidad 4

Aprendizaje Automático · Maestría en Inteligencia Artificial · TecNM Virtual · Alumno(a): Nombre Apellido

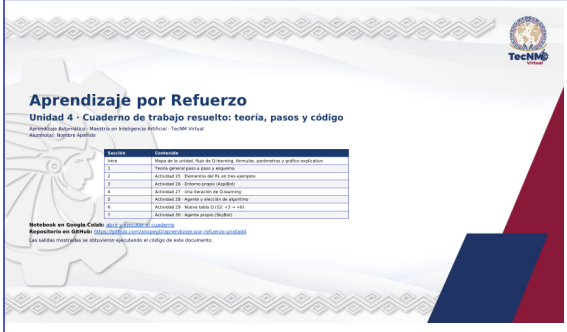
Este documento acompaña al PDF de 34 diapositivas. Para cada una indica **qué muestra**, **cómo se explica paso a paso** y cuál es su **idea clave**, de modo que sirva para estudiar o para exponer.

▶ Abrir el cuaderno en Google Colab
Repositorio en GitHub

Diap.	Tema
1	Portada
2	Introducción · Mapa de toda la unidad
3	Introducción · Cómo aprende un agente: el algoritmo Q-learning
4	Introducción · Fórmulas esenciales (1/2)
5	Introducción · Fórmulas esenciales (2/2)
6	Introducción · Los tres parámetros: γ, α y ε
7	Introducción · Glosario de símbolos
8	Introducción · Gráfico explicativo: anatomía de una actualización de Q-learning
9	1. Teoría general paso a paso
10	Esquema de la teoría
11	2. Actividad 25 · Teoría: cómo reconocer cada elemento
12	Actividad 25 · Resultado: tabla de los tres ejemplos
13	Actividad 25 · Ciclo agente–entorno y papel de la recompensa
14	Actividad 25 · Código: la recompensa como función
15	3. Actividad 26 · Teoría: cómo se diseña un problema de RL
16	Actividad 26 · Diseño de AspiBot y simulación
17	Actividad 26 · Gráficos de aprendizaje y conclusión
18	4. Actividad 27 · Teoría: de Bellman a Q-learning
19	Actividad 27 · Entorno y código de la actualización
20	Actividad 27 · Salida y tabla de cálculos
21	Actividad 27 · Gráfico de evolución y conclusión
22	5. Actividad 28 · Teoría: mapa de algoritmos
23	Actividad 28 · El agente de semáforos y la comparación
24	Actividad 28 · Código: tamaño de la tabla y objetivo de DQN
25	Actividad 28 · Gráficos: la tabla no escala y árbol de decisión
26	6. Actividad 29 · Teoría: valores óptimos y sensibilidad
27	Actividad 29 · Código
28	Actividad 29 · Salida: tablas Q y políticas
29	Actividad 29 · Gráficos: políticas y umbral
30	Actividad 29 · Análisis
31	7. Actividad 30 · Teoría: tipos de refuerzo
32	Actividad 30 · Diseño de SkyBot
33	Actividad 30 · Código de recompensas y política ε-greedy
34	Actividad 30 · Gráficos de SkyBot

Introducción

Diapositiva 1 · Portada



Qué muestra

El título del trabajo, el índice de secciones, el nombre del alumno y los enlaces a Colab y GitHub.

Explicación paso a paso

- Presenta el documento: **Aprendizaje por Refuerzo, Unidad 4**, resuelto con teoría, pasos y código.
- El índice lista la introducción y las 7 secciones (teoría general y Actividades 25 a 30).
- Los enlaces azules son clicables: **Colab** abre el cuaderno para ejecutarlo; **GitHub** abre el repositorio con todo el código y los PDFs.

Idea clave

Es el punto de entrada: indica qué contiene el documento y dónde está el código ejecutable. Recuerda sustituir «Nombre Apellido» por tu nombre.

Diapositiva 2 · Introducción · Mapa de toda la unidad



Qué muestra

Un diagrama con los tres bloques de la unidad (4.1, 4.2, 4.3), sus temas y las actividades que corresponden a cada uno.

Explicación paso a paso

- Arriba, la definición en una frase: un agente aprende a decidir interactuando con un entorno para **maximizar la recompensa acumulada**.
- **4.1 Definición y conceptos básicos** (Act. 25 y 26): medio ambiente, estado, acción, recompensa, política y valor. Es el **vocabulario**.
- **4.2 Algoritmos** (Act. 27 y 28): valores, políticas y modelos; la ecuación de Bellman y cómo elegir algoritmo. Es el **cálculo**.
- **4.3 Tipos y modelos** (Act. 29 y 30): refuerzo positivo y negativo, procesos de Markov, Q-learning y análisis de la recompensa. Es el **análisis y diseño**.
- Las flechas indican el orden recomendado: primero se aprende el lenguaje, después a calcular y por último a analizar y diseñar.

Idea clave

Toda la unidad se resume en un ciclo: estado → acción → recompensa → nuevo estado → aprender.

Diapositiva 3 · Introducción · Cómo aprende un agente: el algoritmo Q-learning



Qué muestra

Un diagrama de flujo con los 7 pasos de Q-learning y la flecha que repite el ciclo.

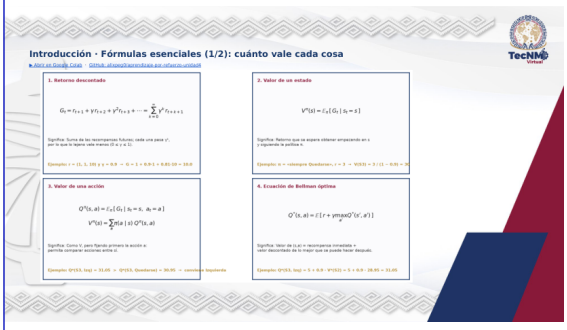
Explicación paso a paso

- **1. Inicializar:** la tabla Q(s,a) empieza en 0 porque el agente no sabe nada.
- **2. Observar el estado** s en el que está.
- **3. Elegir la acción** con ε-greedy: al azar con probabilidad ε (explorar) o la de mayor Q con 1−ε (explotar).
- **4. Ejecutar:** el entorno responde con la recompensa r y el nuevo estado s'.
- **5. Calcular el objetivo** y = r + γ·max Q(s',·): lo que ahora se cree que vale esa acción.
- **6. Actualizar Q** acercándola al objetivo: Q ← Q + α·(y − Q).
- **7. Avanzar** (s ← s'). Si el episodio no terminó, se vuelve a decidir; si terminó, empieza otro.

Idea clave

Repetir este ciclo miles de veces hace que Q se acerque a Q* y que la política greedy sea la óptima.

Diapositiva 4 · Introducción · Fórmulas esenciales (1/2)



Qué muestra

Cuatro tarjetas: retorno descontado, valor de un estado, valor de una acción y ecuación de Bellman. Cada una trae fórmula, significado y ejemplo numérico.

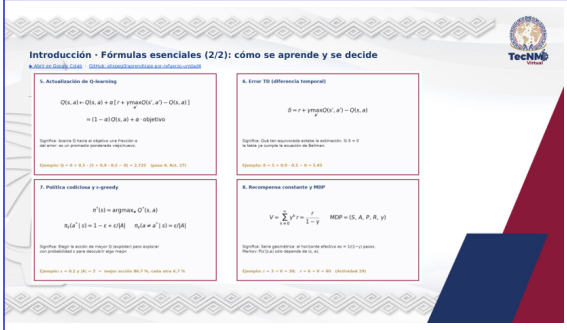
Explicación paso a paso

- **Retorno G:** suma de recompensas futuras, cada una multiplicada por γ^k. Con r = (1, 1, 10) y γ = 0.9: 1 + 0.9·1 + 0.81·10 = **10.0**.
- **V(s):** retorno esperado empezando en s y siguiendo la política. Con «siempre Quedarse» y r = 3: V = 3/(1−0.9) = **30**.
- **Q(s,a):** igual que V pero fijando primero la acción; sirve para comparar acciones. Q*(S3,Izq) = 31.05 supera a Q*(S3,Quedarse) = 30.95.
- **Bellman óptima:** valor de (s,a) = recompensa inmediata + valor descontado de lo mejor que sigue. Q*(S3,Izq) = 5 + 0.9·28.95 = **31.05**.

Idea clave

Distingue siempre la recompensa (lo inmediato) del valor (lo esperado a futuro): Bellman los conecta.

Diapositiva 5 · Introducción · Fórmulas esenciales (2/2)



Qué muestra

Cuatro tarjetas más: actualización de Q-learning, error TD, política codiciosa con ε-greedy y recompensa constante con MDP.

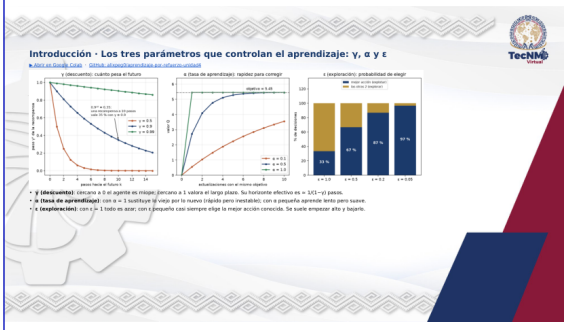
Explicación paso a paso

- **Actualización de Q-learning:** Q ← Q + α·[r + γ·max Q(s',·) − Q]. Es equivalente a un promedio ponderado (1−α)·Q + α·objetivo. Ejemplo: 0 + 0.5·(5 + 0.9·0.5 − 0) = **2.725**.
- **Error TD δ:** diferencia entre el objetivo y la estimación actual (5.45 en el ejemplo). Si δ = 0 la tabla ya cumple Bellman.
- **Política:** π*(s) = argmax Q*(s,a) elige la mejor acción; con ε-greedy la mejor acción tiene probabilidad 1−ε+ε/|A| y cada otra ε/|A| (con ε = 0.2 y 3 acciones: 86.7 % y 6.7 %).
- **Serie geométrica y MDP:** con recompensa constante V = r/(1−γ) (3 → 30, 6 → 60). El MDP es la tupla (S, A, P, R, γ) con propiedad de Markov.

Idea clave

La actualización de Q es una corrección parcial: acerca el valor al objetivo, no lo reemplaza.

Diapositiva 6 · Introducción · Los tres parámetros: γ, α y ε



Qué muestra

Tres gráficas, una por parámetro, que muestran cómo cambian el aprendizaje.

Explicación paso a paso

- **γ (descuento):** curvas del peso γ^k. Con γ = 0.5 el futuro se desvanece enseguida; con 0.99 casi no pierde peso. Con 0.9, una recompensa a 10 pasos vale 0.35.
- **α (tasa de aprendizaje):** cómo Q se acerca al objetivo 5.45 tras repetir la actualización. α = 1 llega de inmediato (pero es inestable), α = 0.5 converge rápido y α = 0.1 es lento y suave.
- **ε (exploración):** barras con la probabilidad de elegir la mejor acción (33 %, 67 %, 87 %, 97 % para ε = 1, 0.5, 0.2, 0.05). Se empieza explorando mucho y se reduce.

Idea clave

Los tres parámetros controlan el equilibrio entre rapidez, estabilidad, visión de futuro y exploración.

Diapositiva 7 · Introducción · Glosario de símbolos



Qué muestra

Una tabla con cada símbolo, cómo se lee, su significado y valores típicos.

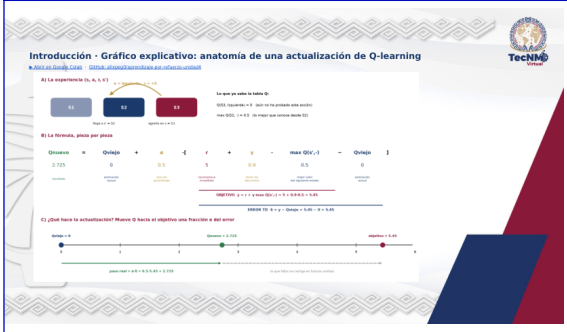
Explicación paso a paso

- Sirve como **referencia rápida** mientras se leen las fórmulas: s, a, r, π, G, γ, α, ε, V, Q, Q*, δ y P(s'|s,a).
- La columna «Valores típicos» da ejemplos concretos de este trabajo (por ejemplo V*(S2) = 28.95 o δ = 5.45) para que cada símbolo tenga un número asociado.

Idea clave

Si aparece un símbolo que no se recuerda, esta diapositiva lo resuelve.

Diapositiva 8 · Introducción · Gráfico explicativo: anatomía de una actualización de Q-learning



Qué muestra

Un gráfico en tres partes que desglosa el paso 4 de la Actividad 27 con números reales.

Explicación paso a paso

- **A) La experiencia:** el agente está en S3, hace Izquierda, recibe r = +5 y llega a S2. La tabla dice que Q(S3,Izq) = 0 y que max Q(S2,·) = 0.5.
- **B) La fórmula pieza por pieza:** cada símbolo aparece con su color y su valor (α = 0.5, r = 5, γ = 0.9, max = 0.5). El **objetivo** vale 5 + 0.9·0.5 = 5.45 y el **error TD** 5.45 − 0 = 5.45.
- **C) El resultado:** en una recta numérica, Q pasa de 0 a **2.725**: avanza α·δ = 0.5·5.45, la mitad del camino hacia el objetivo. El resto se corrige en visitas futuras.

Idea clave

Es la diapositiva clave de la introducción: muestra, con un caso real, qué hace cada símbolo de la fórmula.

Teoría general

Diapositiva 9 · 1. Teoría general paso a paso



Qué muestra

Diez pasos numerados con las ideas centrales del aprendizaje por refuerzo.

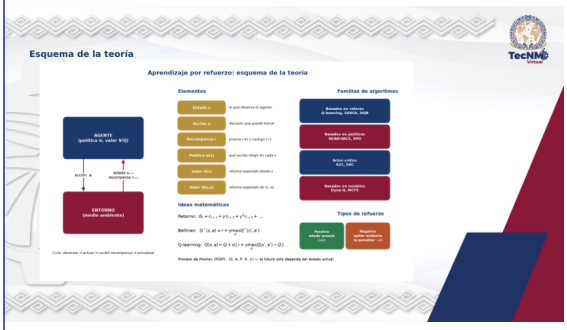
Explicación paso a paso

- Pasos 1–3: qué es el RL, el ciclo agente–entorno y los seis elementos (medio ambiente, estado, acción, recompensa, política y valor).
- Pasos 4–6: retorno con descuento γ, modelo de Markov (MDP) y ecuación de Bellman.
- Pasos 7–8: la regla de Q-learning con su error TD y la estrategia ε-greedy.
- Pasos 9–10: familias de algoritmos (valores, políticas, actor-crítico, modelos) y tipos de refuerzo (positivo, negativo y castigo).

Idea clave

Es el resumen teórico en el que se apoyan las seis actividades.

Diapositiva 10 · Esquema de la teoría



Qué muestra

Un esquema visual con el ciclo agente–entorno, los elementos, las fórmulas, las familias de algoritmos y los tipos de refuerzo.

Explicación paso a paso

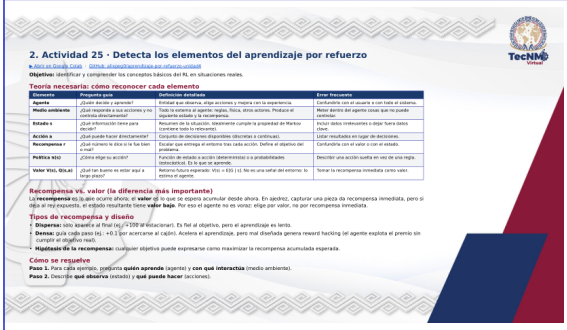
- A la izquierda, el **ciclo**: el agente envía una acción; el entorno devuelve estado y recompensa.
- En el centro, los **elementos** y las fórmulas de retorno, Bellman y Q-learning.
- A la derecha, las **familias de algoritmos** y los tipos de refuerzo positivo y negativo.

Idea clave

Es una vista de conjunto para repasar la teoría de un vistazo.

Actividad 25

Diapositiva 11 · 2. Actividad 25 · Teoría: cómo reconocer cada elemento



Qué muestra

El objetivo de la actividad, una tabla para identificar los elementos del RL y varias ideas de apoyo.

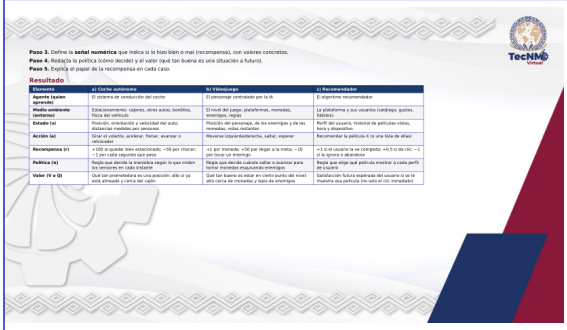
Explicación paso a paso

- La tabla da, para cada elemento (agente, entorno, estado, acción, recompensa, política y valor), una **pregunta guía**, una definición y el **error más frecuente**.
- **Recompensa vs. valor:** la recompensa es lo inmediato; el valor, lo que se espera acumular. En ajedrez, capturar una pieza da recompensa pero puede dejar un estado de valor bajo.
- **Tipos de recompensa:** dispersa (solo al final) y densa (guía cada paso, con el riesgo de *reward hacking*).
- Después aparece la receta «Cómo se resuelve» en cinco pasos.

Idea clave

Con la pregunta guía correcta, identificar los elementos en cualquier ejemplo es mecánico.

Diapositiva 12 · Actividad 25 · Resultado: tabla de los tres ejemplos



Qué muestra

Los pasos finales de la receta y la tabla con los seis elementos para el coche autónomo, el videojuego y el recomendador.

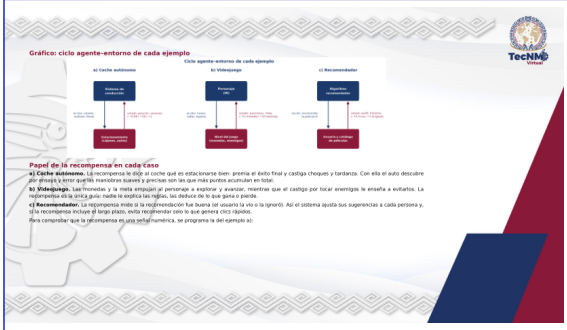
Explicación paso a paso

- **Coche autónomo:** el agente es el sistema de conducción; el entorno, el estacionamiento; las recompensas, +100 al estacionar, −50 por chocar y −1 por segundo.
- **Videojuego:** el agente es el personaje; las recompensas son +1 por moneda, +50 por la meta y −10 por tocar un enemigo.
- **Recomendador:** el agente es el algoritmo; el entorno, usuarios y catálogo; la recompensa, +1 si ve la película y −1 si la ignora.
- Cada ejemplo distingue política (cómo decide) y valor (qué tan buena es una situación a largo plazo).

Idea clave

Es el entregable principal de la actividad: la tabla completa con los seis elementos en los tres casos.

Diapositiva 13 · Actividad 25 · Ciclo agente–entorno y papel de la recompensa



Qué muestra

Un gráfico del ciclo de cada ejemplo y los párrafos que explican el papel de la recompensa.

Explicación paso a paso

- El gráfico dibuja, por ejemplo, el agente arriba y el entorno abajo, con la **acción** bajando y el **estado y la recompensa** subiendo.
- Cada párrafo explica la función de la recompensa: en el coche premia el éxito y castiga choques y tardanza; en el videojuego es la única guía del personaje; en el recomendador mide si la recomendación fue buena y puede incluir el largo plazo.

Idea clave

La recompensa es la señal que define qué significa «hacerlo bien» en cada problema.

Diapositiva 14 · Actividad 25 · Código: la recompensa como función



Qué muestra

Una función en Python que calcula la recompensa del coche y su salida.

Explicación paso a paso

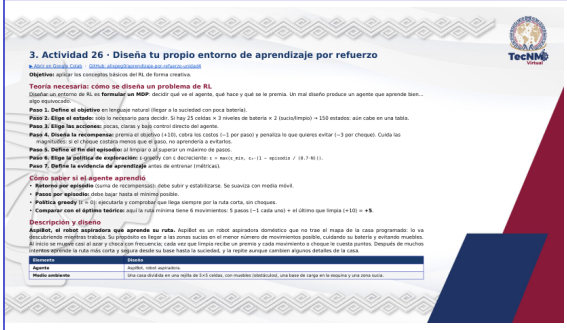
- La función parte de −1 por cada segundo, resta 50 si choca y suma 100 si estaciona.
- Salida: **maniobrando = −1**, **chocó = −51** y **estacionó bien = +99**.
- Demuestra que la recompensa es un **número** que se puede programar.

Idea clave

Traducir el objetivo a una función numérica es el primer paso para entrenar a un agente.

Actividad 26

Diapositiva 15 · 3. Actividad 26 · Teoría: cómo se diseña un problema de RL



Qué muestra

Los pasos para diseñar un entorno de RL, cómo medir el aprendizaje y el inicio del diseño de AspiBot.

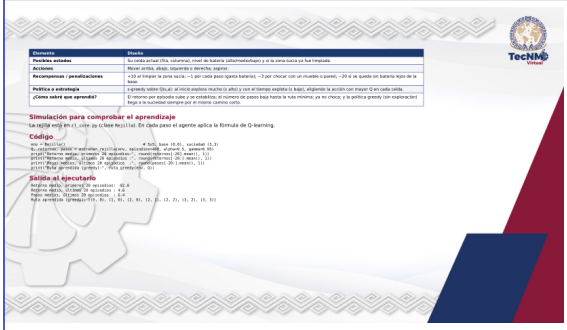
Explicación paso a paso

- Diseñar un entorno es **formular un MDP**: objetivo, estado, acciones, recompensa, fin de episodio, política de exploración y evidencia de aprendizaje.
- Ejemplo de tamaño de estado: 25 celdas × 3 niveles de batería × 2 (sucio/limpio) = 150 estados, que todavía caben en una tabla.
- Las magnitudes importan: si chocar costara menos que dar un paso, el agente no aprendería a evitar choques.
- Para saber si aprendió: retorno que sube y se estabiliza, pasos que bajan, política greedy sin choques y comparación con el óptimo (+5 en 6 movimientos).

Idea clave

Antes de entrenar hay que decidir cómo se va a comprobar que el agente aprendió.

Diapositiva 16 · Actividad 26 · Diseño de AspiBot y simulación



Qué muestra

El resto de la tabla de diseño y el código de la simulación con su salida.

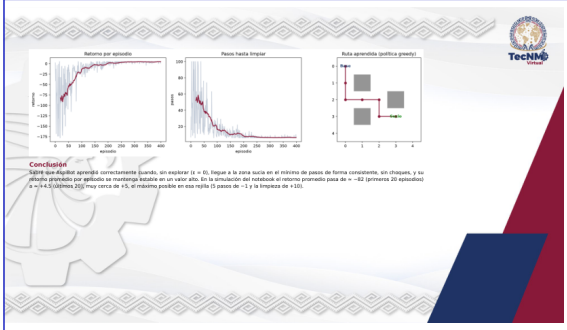
Explicación paso a paso

- La tabla incluye acciones (cuatro movimientos y aspirar), recompensas (+10 limpiar, −1 por paso, −3 por choque, −20 por quedarse sin batería), política ε-greedy y la evidencia de aprendizaje.
- El código entrena a AspiBot 400 episodios con $\alpha = 0.5$ y $\gamma = 0.95$, e imprime el retorno medio al inicio y al final, los pasos y la ruta aprendida.

Idea clave

La simulación convierte el diseño en una prueba: se ve si el agente realmente mejora.

Diapositiva 17 · Actividad 26 · Gráficos de aprendizaje y conclusión



Qué muestra

Tres gráficos (retorno, pasos y ruta) y la conclusión de la actividad.

Explicación paso a paso

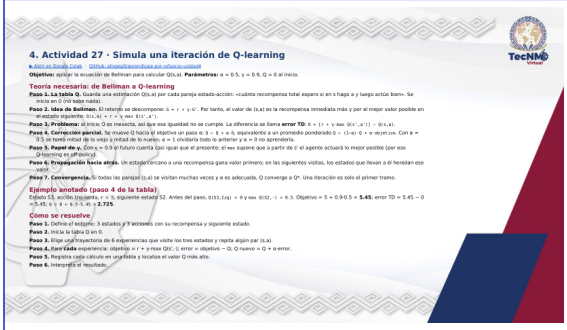
- **Retorno por episodio:** pasa de ≈ −82 en los primeros 20 episodios a ≈ +4.5 en los últimos 20, cerca del máximo posible (+5).
- **Pasos hasta limpiar:** bajan hasta unos 6, la ruta más corta.
- **Ruta aprendida:** la política greedy rodea los obstáculos y llega a la suciedad en 6 movimientos.
- La conclusión resume los criterios para decir que el agente aprendió.

Idea clave

Las curvas son la evidencia: sin ellas, «aprendió» sería solo una afirmación.

Actividad 27

Diapositiva 18 · 4. Actividad 27 · Teoría: de Bellman a Q-learning



Qué muestra

Los siete pasos teóricos de Q-learning, un ejemplo anotado y la receta de resolución.

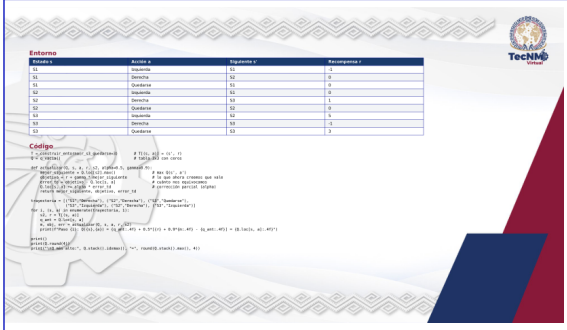
Explicación paso a paso

- **Tabla Q:** una estimación por pareja estado–acción, iniciada en 0.
- **Bellman:** Q(s,a) = r + γ·max Q(s',a'). Mientras Q sea inexacta, la diferencia es el **error TD**.
- **Corrección parcial:** Q ← Q + α·δ, un promedio ponderado entre lo viejo y lo nuevo.
- **Propagación hacia atrás:** los estados cercanos a una recompensa ganan valor primero y luego lo heredan los anteriores.
- **Ejemplo anotado (paso 4):** objetivo 5 + 0.9·0.5 = 5.45; error 5.45; Q = 0 + 0.5·5.45 = **2.725**.

Idea clave

Q-learning corrige poco a poco una tabla hasta que cumple la ecuación de Bellman.

Diapositiva 19 · Actividad 27 · Entorno y código de la actualización



Qué muestra

La tabla de reglas del entorno (3 estados × 3 acciones) y el código que aplica Q-learning.

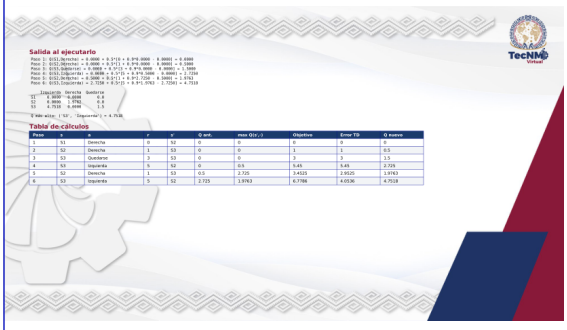
Explicación paso a paso

- La tabla indica, para cada (estado, acción), el siguiente estado y la recompensa; por ejemplo (S3, Izquierda) → S2 con +5 y (S3, Quedarse) → S3 con +3.
- La función actualizar calcula el mejor valor siguiente, el objetivo, el error TD y aplica la corrección con α.
- La trayectoria tiene 6 experiencias que recorren los tres estados y repiten algunos pares.

Idea clave

El código es una traducción literal de la receta de siete pasos.

Diapositiva 20 · Actividad 27 · Salida y tabla de cálculos



Qué muestra

La salida del código y la tabla con los 6 pasos.

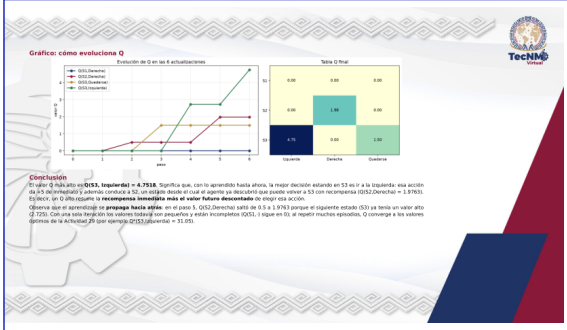
Explicación paso a paso

- Los seis nuevos valores de Q son: 0, 0.5, 1.5, **2.725**, **1.9763** y **4.7518**.
- En el paso 5 Q(S2,Derecha) sube de 0.5 a 1.9763 porque el estado siguiente ya tiene valor alto: así se **propaga el aprendizaje hacia atrás**.
- La tabla Q final deja Q(S3,Izq) = 4.7518 como el valor más alto.

Idea clave

Cada fila de la tabla es una aplicación completa de la fórmula con sus valores.

Diapositiva 21 · Actividad 27 · Gráfico de evolución y conclusión



Qué muestra

Líneas con la evolución de cuatro valores Q, la tabla Q final como mapa de calor y la conclusión.

Explicación paso a paso

- Las líneas muestran **cuándo** se actualiza cada Q y cuánto sube; Q(S3,Izq) llega a ≈ 4.75.
- El mapa de calor destaca los valores más altos en azul oscuro.
- La conclusión explica que el Q más alto resume la **recompensa inmediata más el valor futuro descontado**, y que con más episodios Q converge a Q*.

Idea clave

Una iteración solo da el primer tramo del aprendizaje; los valores finales (≈ 31) llegan con muchos episodios.

Actividad 28

Diapositiva 22 · 5. Actividad 28 · Teoría: mapa de algoritmos



Qué muestra

Una tabla con seis algoritmos, los criterios de decisión y el inicio de la receta de resolución.

Explicación paso a paso

- La tabla compara **Q-learning tabular, SARSA, DQN, REINFORCE/PPO, actor-crítico y Dyna-Q**: cómo funcionan, su fortaleza y su limitación.
- Los criterios son tres preguntas: ¿cuántos estados?, ¿las acciones son discretas o continuas? y ¿se puede simular el entorno?
- DQN usa una red neuronal para estimar Q, con memoria de repetición y red objetivo.

Idea clave

Elegir algoritmo es contestar preguntas sobre el problema, no escoger el más famoso.

Diapositiva 23 · Actividad 28 · El agente de semáforos y la comparación



Qué muestra

El resto de la receta, la tabla del agente y la comparación de algoritmos aplicada.

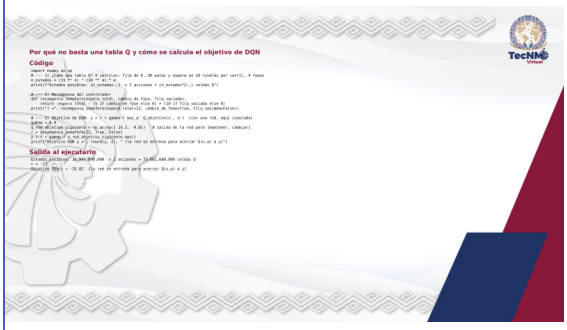
Explicación paso a paso

- El agente es un **controlador de semáforos**; sus acciones son mantener o cambiar la fase y su recompensa penaliza la espera total y los cambios excesivos.
- El algoritmo elegido es **DQN** porque el espacio de estados es enorme y las acciones son pocas y discretas.
- La comparación explica por qué se descartan Q-learning tabular, PPO y Dyna-Q para este caso.

Idea clave

La justificación se apoya en las características del problema.

Diapositiva 24 · Actividad 28 · Código: tamaño de la tabla y objetivo de DQN



Qué muestra

Código con tres cálculos y su salida.

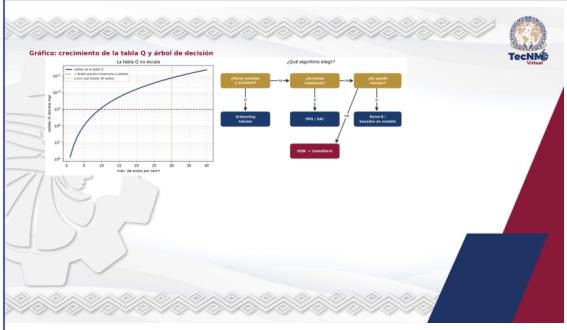
Explicación paso a paso

- **Tamaño:** $31^4 \cdot 10^4 \cdot 4 \approx 36\,940\,840\,000$ estados × 2 acciones ≈ 73 881 680 000 celdas Q: inviable.
- **Recompensa:** con espera 12 y cambio de fase da $r = -17$.
- **Objetivo de DQN:** $y = r + \gamma \cdot \max Q = -17 + 0.9 \cdot (-9.8) =$ **-25.82**, el valor al que se acerca la red.

Idea clave

DQN conserva la lógica de Q-learning y cambia la tabla por una red.

Diapositiva 25 · Actividad 28 · Gráficos: la tabla no escala y árbol de decisión



Qué muestra

Una curva del crecimiento de la tabla Q y un árbol de decisión para elegir algoritmo.

Explicación paso a paso

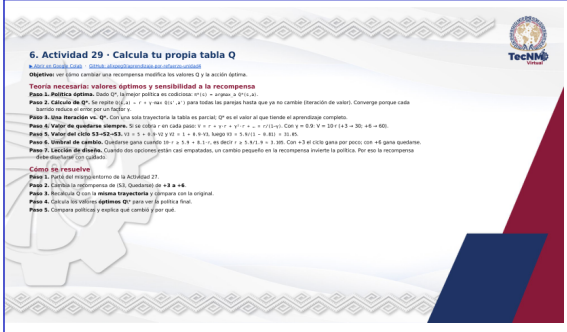
- La curva (escala logarítmica) supera el límite práctico (≈ 10^9 celdas) hacia los 10 autos por carril, mucho antes de los 30 de un cruce real.
- El árbol: pocos estados → Q-learning tabular; acciones continuas → PPO o SAC; se puede simular → Dyna-Q; en otro caso → **DQN**.

Idea clave

El árbol resume el criterio de decisión de la actividad.

Actividad 29

Diapositiva 26 · 6. Actividad 29 · Teoría: valores óptimos y sensibilidad



Qué muestra

Siete pasos teóricos sobre Q* y la receta de la actividad.

Explicación paso a paso

- La política óptima es π*(s) = argmax Q*(s,a), y Q* se obtiene repitiendo Bellman hasta converger.
- **Quedarse siempre** vale r/(1−γ); el **ciclo S3→S2→S3** vale 5.9/(1−0.81) = 31.05.
- **Umbral:** quedarse gana cuando r ≥ 5.9/1.9 ≈ **3.105**. Con +3 gana el ciclo por poco; con +6 gana quedarse.
- Lección: cuando dos opciones están casi empatadas, un cambio pequeño de recompensa invierte la política.

Idea clave

Una recompensa mal calibrada puede cambiar el comportamiento del agente.

Diapositiva 27 · Actividad 29 · Código



Qué muestra

Código que compara el entorno original (+3) con el modificado (+6).

Explicación paso a paso

- Tres bloques: **una iteración** con la misma trayectoria; los **valores óptimos Q*** de ambos entornos; y una comprobación con **Q-learning entrenado**.

Idea clave

Se compara con el mismo procedimiento para que la única diferencia sea la recompensa.

Diapositiva 28 · Actividad 29 · Salida: tablas Q y políticas



Qué muestra

Las tablas Q tras una iteración y las tablas Q* con las políticas.

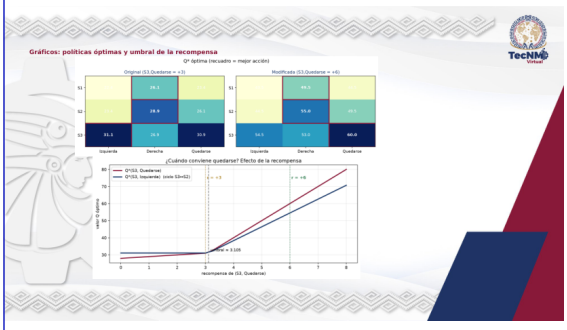
Explicación paso a paso

- Tras una iteración, Q(S3,Quedarse) pasa de 1.5 a 3.0 con la nueva recompensa.
- Q* original: S3 → Izquierda (31.05 vs 30.95). Q* nueva: S3 → **Quedarse** (60 vs 54.5).
- Q-learning entrenado llega a la misma política que la solución exacta.

Idea clave

La política cambia solo en S3, justo donde se modificó la recompensa.

Diapositiva 29 · Actividad 29 · Gráficos: políticas y umbral



Qué muestra

Dos mapas de calor de Q* (original y modificada) y una curva de Q*(S3,·) según la recompensa.

Explicación paso a paso

- Los recuadros marcan la mejor acción por estado; en S3 el recuadro pasa de «Izquierda» a «Quedarse».
- La curva muestra el **cruce** en ≈ 3.105; las líneas punteadas marcan +3 (justo antes) y +6 (claramente después).

Idea clave

El gráfico explica visualmente por qué +3 y +6 llevan a políticas distintas.

Diapositiva 30 · Actividad 29 · Análisis



Qué muestra

Las respuestas a las dos preguntas de la actividad.

Explicación paso a paso

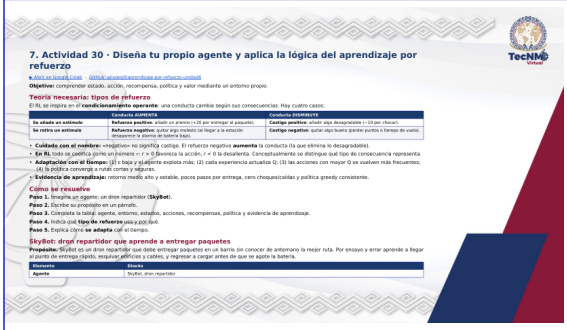
- **¿Qué cambió?** En S3 la acción óptima pasó de Izquierda a Quedarse y todos los Q suben.
- **¿Por qué?** Quedarse produce V(S3) = 6/(1−0.9) = 60, mientras que el ciclo rinde ≈ 54.5; al duplicar la recompensa, quedarse supera al ciclo.

Idea clave

El valor de una acción es la recompensa inmediata más el valor futuro descontado.

Actividad 30

Diapositiva 31 · 7. Actividad 30 · Teoría: tipos de refuerzo



Qué muestra

Una tabla de condicionamiento operante e ideas sobre cómo se adapta el agente.

Explicación paso a paso

- La tabla 2×2: refuerzo **positivo** (añadir un premio), **negativo** (retirar algo molesto), castigo **positivo** (añadir algo desagradable) y castigo **negativo** (quitar algo bueno).
- «Negativo» no es castigo: el refuerzo negativo **aumenta** la conducta.
- En RL todo se codifica como un número r; r > 0 favorece y r < 0 desalienta.
- La adaptación ocurre porque ε baja, Q se actualiza y la política converge.

Idea clave

Conviene distinguir conceptualmente el tipo de consecuencia aunque en el código sea solo un signo.

Diapositiva 32 · Actividad 30 · Diseño de SkyBot



Qué muestra

La descripción de SkyBot, la tabla de diseño y el tipo de refuerzo.

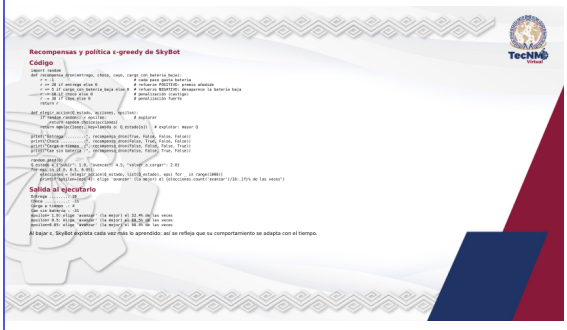
Explicación paso a paso

- SkyBot es un dron repartidor que aprende rutas cortas, evita obstáculos y recarga a tiempo.
- La tabla cubre agente, entorno, estados, acciones, recompensas, política y evidencia de aprendizaje.
- Usa **ambos refuerzos**: positivo (+20 al entregar), negativo (desaparece la batería baja al cargar) y penalizaciones por chocar o caer.

Idea clave

Cada columna de la tabla corresponde a un elemento visto en la unidad.

Diapositiva 33 · Actividad 30 · Código de recompensas y política ε-greedy



Qué muestra

Dos funciones (recompensa y elección de acción) y su salida.

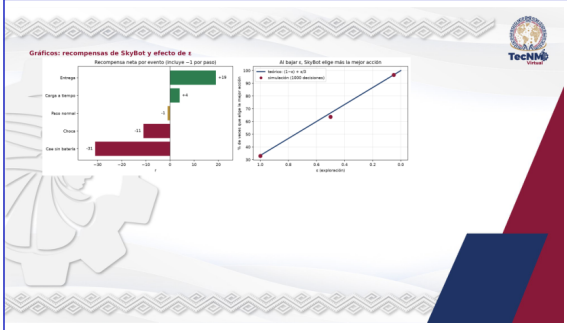
Explicación paso a paso

- Recompensas netas: **entrega = +19**, **carga a tiempo = +4**, **choque = −11**, **caída = −31** (incluyen el −1 por paso).
- La elección de acción con ε = 1, 0.5 y 0.05 muestra que la mejor acción se elige cada vez más (cerca de 33 %, 67 % y 97 %).

Idea clave

Al bajar ε el agente explota lo aprendido: así se adapta con el tiempo.

Diapositiva 34 · Actividad 30 · Gráficos de SkyBot



Qué muestra

Una gráfica de barras con la recompensa de cada evento y una curva del efecto de ε.

Explicación paso a paso

- Las barras verdes son premios; las guindas, castigos. La caída es el evento más costoso.
- La curva teórica $(1-\varepsilon)+\varepsilon/3$ coincide con los puntos de la simulación.

Idea clave

Cierra el documento mostrando recompensas y exploración en un solo vistazo.