Aprendizaje por Refuerzo

Unidad 4 · Cuaderno de trabajo resuelto, paso a paso y con código

Aprendizaje Automático · Maestría en Inteligencia Artificial · TecNM Virtual
Alumno(a): Nombre Apellido

Sección	Contenido
1	Teoría paso a paso y esquema
2	Actividad 25 · Elementos del RL en tres ejemplos
3	Actividad 26 · Entorno propio (AspiBot)
4	Actividad 27 · Una iteración de Q-learning
5	Actividad 28 · Agente y elección de algoritmo
6	Actividad 29 · Nueva tabla Q (S3: +3 → +6)
7	Actividad 30 · Agente propio (SkyBot)

El código completo (ejecutable en Google Colab) está en: https://github.com/alixpeg0/aprendizaje-por-refuerzo-unidad4. Todas las salidas de este documento se obtuvieron ejecutando el código mostrado.

1. Teoría paso a paso

Paso 1. ¿Qué es el aprendizaje por refuerzo?. Un **agente** aprende a decidir **interactuando** con un entorno. No recibe ejemplos etiquetados: recibe **recompensas** y descubre por ensayo y error qué acciones convienen. Su meta es maximizar la recompensa **total acumulada**, no solo la inmediata.

Paso 2. Ciclo agente–entorno. En cada instante: el agente observa el estado `s`, elige una acción `a`, el entorno responde con una recompensa `r` y un nuevo estado `s'`, y el agente aprende de la experiencia `(s, a, r, s')`.

Paso 3. Seis elementos básicos. Medio ambiente (lo externo), **estado** (situación actual), **acción** (lo que puede hacer), **recompensa** (número que dice qué tan bueno fue lo ocurrido), **política** π(s) (regla que elige acción por estado) y **valor** V(s) o Q(s,a) (recompensa futura esperada). La recompensa es lo de *ahora*; el valor, lo esperado *de aquí en adelante*.

Paso 4. Retorno y descuento γ. El agente maximiza $G = r_1 + \gamma \cdot r_2 + \gamma^2 \cdot r_3 + \ldots$ con $0 \leq \gamma \leq 1$. Con γ cercano a 0 es miope; cercano a 1, previsor. Con γ = 0.9, una recompensa dentro de 2 pasos vale 0.81 de su valor.

Paso 5. Procesos de decisión de Markov (MDP). Es el modelo formal: (S, A, P, R, γ). Propiedad de Markov: el futuro depende **solo del estado actual**.

Paso 6. Ecuación de Bellman. El valor es recursivo: *recompensa inmediata + valor descontado de lo que sigue*. $Q^*(s,a) = r + \gamma \cdot \max Q^*(s',a')$.

Paso 7. Q-learning. Sin conocer el entorno, estima Q con cada experiencia: $Q(s,a) \leftarrow Q(s,a) + \alpha \cdot [\, r + \gamma \cdot \max Q(s',a') - Q(s,a) \,]$. α es la tasa de aprendizaje; el corchete es el **error TD** (objetivo − estimación actual). Es *off-policy*.

Paso 8. Exploración vs. explotación (ε-greedy). Con probabilidad ε se elige una acción al azar (explorar) y con 1−ε la de mayor Q (explotar). Se suele empezar con ε alto y reducirlo.

Paso 9. Familias de algoritmos. Basados en valores (Q-learning, SARSA, DQN: acciones discretas), **en políticas** (REINFORCE, PPO: acciones continuas), **actor-crítico** (A2C, SAC) y **basados en modelos** (Dyna-Q, MCTS: cuando se puede simular).

Paso 10. Tipos de refuerzo. Positivo: se añade un premio para que la conducta aumente. **Negativo:** se retira algo desagradable para que aumente. **Castigo/penalización:** se añade algo desagradable para que disminuya (en RL se escribe como $r < 0$).

Receta para aplicar Q-learning a mano

Paso 1. Identifica `s`, `a`, `r` y `s'` de la experiencia.

Paso 2. Lee $Q(s,a)$ actual en la tabla.

Paso 3. Lee $\max Q(s',\cdot)$: el mejor valor del estado siguiente.

Paso 4. Objetivo = $r + \gamma \cdot \max Q(s',\cdot)$.

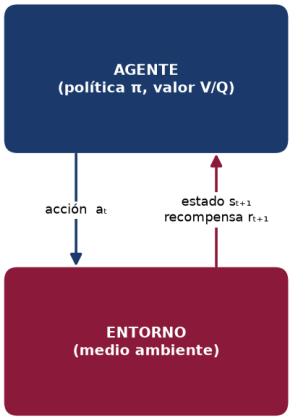
Paso 5. Error TD = objetivo − $Q(s,a)$.

Paso 6. Nuevo $Q(s,a) = Q(s,a) + \alpha \cdot \text{error}$.

Paso 7. Repite con la siguiente experiencia.

Esquema de la teoría

Aprendizaje por refuerzo: esquema de la teoría



Ciclo: observar → actuar → recibir recompensa → actualizar

Elementos

Estado s	lo que observa el agente
Acción a	decisión que puede tomar
Recompensa r	premio (+) o castigo (−)
Política π(s)	qué acción elegir en cada s
Valor V(s)	retorno esperado desde s
Valor Q(s,a)	retorno esperado de (s, a)

Familias de algoritmos

- **Basados en valores** — Q-learning, SARSA, DQN
- **Basados en políticas** — REINFORCE, PPO
- **Actor-crítico** — A2C, SAC
- **Basados en modelos** — Dyna-Q, MCTS

Ideas matemáticas

Retorno: $G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \ldots$

Bellman: $Q^*(s,a) = r + \gamma \max_{a'} Q^*(s',a')$

Q-learning: $Q(s,a) \leftarrow Q + \alpha\,[\, r + \gamma \max_{a'} Q(s',a') - Q\,]$

Proceso de Markov (MDP): (S, A, P, R, γ) — el futuro solo depende del estado actual

Tipos de refuerzo

- **Positivo** — añadir premio (+r)
- **Negativo** — quitar molestia (o penalizar −r)

2. Actividad 25 · Detecta los elementos del aprendizaje por refuerzo

Objetivo: identificar los conceptos básicos del RL en situaciones reales.

Cómo se resuelve

Paso 1. Para cada ejemplo, pregunta **quién aprende** (agente) y **con qué interactúa** (medio ambiente).

Paso 2. Describe **qué observa** el agente (estado) y **qué puede hacer** (acciones).

Paso 3. Define **qué señal** le dice si lo hizo bien o mal (recompensa), con valores concretos.

Paso 4. Redacta la política (cómo decide) y el valor (qué tan buena es una situación a futuro).

Paso 5. Explica el papel de la recompensa en cada caso.

Resultado

Elemento	a) Coche	b) Videojuego	c) Recomendador
Agente (quien aprende)	El sistema de conducción del coche	El personaje controlado por la IA	El algoritmo recomendador
Medio ambiente (entorno)	Estacionamiento: cajones, otros autos, bordillos, física del vehículo	El nivel del juego: plataformas, monedas, enemigos, reglas	La plataforma y sus usuarios (catálogo, gustos, hábitos)
Estado (s)	Posición, orientación y velocidad del auto; distancias medidas por sensores	Posición del personaje, de los enemigos y de las monedas; vidas restantes	Perfil del usuario, historial de películas vistas, hora y dispositivo
Acción (a)	Girar el volante, acelerar, frenar, avanzar o retroceder	Moverse izquierda/derecha, saltar, esperar	Recomendar la película X (o una lista de ellas)
Recompensa (r)	+100 al quedar bien estacionado; −50 por chocar; −1 por cada segundo que pasa	+1 por moneda; +50 por llegar a la meta; −10 por tocar un enemigo	+1 si el usuario la ve completa; +0.5 si da clic; −1 si la ignora o abandona
Política (π)	Regla que decide la maniobra según lo que miden los sensores en cada instante	Regla que decide cuándo saltar o avanzar para tomar monedas esquivando enemigos	Regla que elige qué película mostrar a cada perfil de usuario
Valor (V o Q)	Qué tan prometedora es una posición: alto si ya está alineado y cerca del cajón	Qué tan bueno es estar en cierto punto del nivel: alto cerca de monedas y lejos de enemigos	Satisfacción futura esperada del usuario si se le muestra esa película (no solo el clic inmediato)

Papel de la recompensa

a) Coche autónomo. La recompensa le dice al coche qué es estacionarse bien: premia el éxito final y castiga choques y tardanza. Con ella el auto descubre por ensayo y error que las maniobras suaves y precisas son las que más puntos acumulan en total.

b) Videojuego. Las monedas y la meta empujan al personaje a explorar y avanzar, mientras que el castigo por tocar enemigos le enseña a evitarlos. La recompensa es la única guía: nadie le explica las reglas, las deduce de lo que gana o pierde.

c) Recomendador. La recompensa mide si la recomendación fue buena (el usuario la vio o la ignoró). Así el sistema ajusta sus sugerencias a cada persona y, si la recompensa incluye el largo plazo, evita recomendar solo lo que genera clics rápidos.

Código: la recompensa del coche como función

Para comprobar que la recompensa es una **señal numérica** que premia o castiga, se programa la del ejemplo a):

Código

```
def recompensa_coche(estacionado, choco):
    r = -1                # cada segundo cuesta un punto (hay que ser rápido)
    if choco:
        r -= 50           # castigo por chocar
    if estacionado:
        r += 100          # premio por terminar bien
    return r

for situacion, args in {"maniobrando": (False, False), "chocó": (False, True),
                        "estacionó bien": (True, False)}.items():
    print(f"{situacion:15s} -> r = {recompensa_coche(*args):4d}")
```

Salida al ejecutarlo

```
maniobrando     -> r =   -1
chocó           -> r =  -51
estacionó bien  -> r =   99
```

3. Actividad 26 · Diseña tu propio entorno de aprendizaje por refuerzo

Objetivo: aplicar los conceptos básicos de forma creativa.

Cómo se resuelve

Paso 1. Elige un agente: aquí **AspiBot**, un robot aspiradora.

Paso 2. Describe el **entorno**: rejilla 5×5 con muebles y una zona sucia.

Paso 3. Enumera **estados** (celda, batería) y **acciones** (4 movimientos).

Paso 4. Asigna **recompensas**: +10 limpiar, −1 por paso, −3 por choque.

Paso 5. Define la **política**: ε-greedy sobre Q(s,a).

Paso 6. Decide **cómo medir que aprendió**: retorno que sube, pasos que bajan y ruta corta sin choques.

Descripción

AspiBot, el robot aspiradora que aprende su ruta. AspiBot es un robot aspiradora doméstico que no trae el mapa de la casa programado: lo va descubriendo mientras trabaja. Su propósito es llegar a las zonas sucias en el menor número de movimientos posible, cuidando su batería y evitando muebles. Al inicio se mueve casi al azar y choca con frecuencia; cada vez que limpia recibe un premio y cada movimiento o choque le cuesta puntos. Después de muchos intentos aprende la ruta más corta y segura desde su base hasta la suciedad, y la repite aunque cambien algunos detalles de la casa.

Elemento	Diseño
Agente	AspiBot, robot aspiradora.
Medio ambiente	Una casa dividida en una rejilla de 5×5 celdas, con muebles (obstáculos), una base de carga en la esquina y una zona sucia.
Posibles estados	Su celda actual (fila, columna), nivel de batería (alto/medio/bajo) y si la zona sucia ya fue limpiada.
Acciones	Mover arriba, abajo, izquierda o derecha; aspirar.
Recompensas / penalizaciones	+10 al limpiar la zona sucia; −1 por cada paso (gasta batería); −3 por chocar con un mueble o pared; −20 si se queda sin batería lejos de la base.
Política o estrategia	ε-greedy sobre Q(s,a): al inicio explora mucho (ε alto) y con el tiempo explota (ε bajo), eligiendo la acción con mayor Q en cada celda.
¿Cómo sabré que aprendió?	El retorno por episodio sube y se estabiliza; el número de pasos baja hasta la ruta mínima; ya no choca; y la política greedy (sin exploración) llega a la suciedad siempre por el mismo camino corto.

Código: simulación para comprobar el aprendizaje

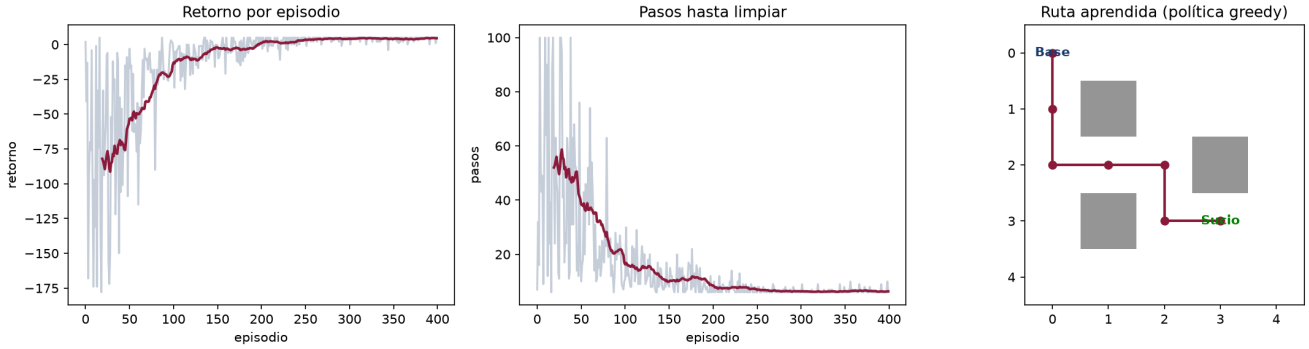
La rejilla se implementa en `rl_core.py` (clase `Rejilla`). El agente aplica la fórmula de Q-learning en cada paso.

Código

```
env = Rejilla()                                  # 5x5, base (0,0), suciedad (3,3)
Q, retornos, pasos = entrenar_rejilla(env, episodios=400, alpha=0.5, gamma=0.95)
print("Retorno medio, primeros 20 episodios:", round(retornos[:20].mean(), 1))
print("Retorno medio, últimos 20 episodios :", round(retornos[-20:].mean(), 1))
print("Pasos medios, últimos 20 episodios  :", round(pasos[-20:].mean(), 1))
print("Ruta aprendida (greedy):", ruta_greedy(env, Q))
```

Salida al ejecutarlo

```
Retorno medio, primeros 20 episodios: -82.0
Retorno medio, últimos 20 episodios : 4.6
Pasos medios, últimos 20 episodios  : 6.4
Ruta aprendida (greedy): [(0, 0), (1, 0), (2, 0), (2, 1), (2, 2), (3, 2), (3, 3)]
```



Conclusión

Sabré que AspiBot aprendió correctamente cuando, sin explorar (ε = 0), llegue a la zona sucia en el mínimo de pasos de forma consistente, sin choques, y su retorno promedio por episodio se mantenga estable en un valor alto. En la simulación del notebook el retorno promedio pasa de ≈ −82 (primeros 20 episodios) a ≈ +4.5 (últimos 20), muy cerca de +5, el máximo posible en esa rejilla (5 pasos de −1 y la limpieza de +10).

4. Actividad 27 · Simula una iteración de Q-learning

Objetivo: aplicar la ecuación de Bellman para calcular Q(s,a). **Parámetros:** α = 0.5, γ = 0.9, Q = 0 al inicio.

Cómo se resuelve

Paso 1. Define el entorno: 3 estados (S1, S2, S3) y 3 acciones (Izquierda, Derecha, Quedarse) con su recompensa y siguiente estado.

Paso 2. Inicia la tabla Q en 0 (3×3).

Paso 3. Elige una trayectoria de 6 experiencias que visite los tres estados y repita algún par (s,a).

Paso 4. Para **cada** experiencia aplica la receta: objetivo = r + γ·max Q(s',·); error = objetivo − Q; Q nuevo = Q + α·error.

Paso 5. Registra cada cálculo en una tabla y localiza el valor Q más alto.

Paso 6. Interpreta el resultado.

Entorno

Estado s	Acción a	Siguiente s'	Recompensa r
S1	Izquierda	S1	-1
S1	Derecha	S2	0
S1	Quedarse	S1	0
S2	Izquierda	S1	0
S2	Derecha	S3	1
S2	Quedarse	S2	0
S3	Izquierda	S2	5
S3	Derecha	S3	-1
S3	Quedarse	S3	3

Código

```
T = construir_entorno(r_s3_quedarse=3)       # T[(s, a)] = (s', r)
Q = q_vacia()                                # tabla 3x3 con ceros

def actualizar(Q, s, a, r, s2, alpha=0.5, gamma=0.9):
    mejor_siguiente = Q.loc[s2].max()                # max Q(s', a')
    objetivo = r + gamma * mejor_siguiente           # lo que ahora creemos que vale
    error_td = objetivo - Q.loc[s, a]                # cuánto nos equivocamos
    Q.loc[s, a] += alpha * error_td                  # corrección parcial (alpha)
    return mejor_siguiente, objetivo, error_td

trayectoria = [("S1","Derecha"), ("S2","Derecha"), ("S3","Quedarse"),
               ("S3","Izquierda"), ("S2","Derecha"), ("S3","Izquierda")]
for i, (s, a) in enumerate(trayectoria, 1):
    s2, r = T[(s, a)]
    q_ant = Q.loc[s, a]
    m, obj, err = actualizar(Q, s, a, r, s2)
    print(f"Paso {i}: Q({s},{a}) = {q_ant:.4f} + 0.5*[{r} + 0.9*{m:.4f} - {q_ant:.4f}] = {Q.loc[s, a]:.4f}")

print()
print(Q.round(4))
print("\nQ más alto:", Q.stack().idxmax(), "=", round(Q.stack().max(), 4))
```

Salida al ejecutarlo

```
Paso 1: Q(S1,Derecha) = 0.0000 + 0.5*[0 + 0.9*0.0000 - 0.0000] = 0.0000
Paso 2: Q(S2,Derecha) = 0.0000 + 0.5*[1 + 0.9*0.0000 - 0.0000] = 0.5000
Paso 3: Q(S3,Quedarse) = 0.0000 + 0.5*[3 + 0.9*0.0000 - 0.0000] = 1.5000
Paso 4: Q(S3,Izquierda) = 0.0000 + 0.5*[5 + 0.9*0.5000 - 0.0000] = 2.7250
Paso 5: Q(S2,Derecha) = 0.5000 + 0.5*[1 + 0.9*2.7250 - 0.5000] = 1.9763
Paso 6: Q(S3,Izquierda) = 2.7250 + 0.5*[5 + 0.9*1.9763 - 2.7250] = 4.7518

    Izquierda  Derecha  Quedarse
S1     0.0000   0.0000       0.0
S2     0.0000   1.9762       0.0
S3     4.7518   0.0000       1.5

Q más alto: ('S3', 'Izquierda') = 4.7518
```

Tabla de cálculos

Paso	s	a	r	s'	Q ant.	max Q(s',·)	Objetivo	Error TD	Q nuevo
1	S1	Derecha	0	S2	0	0	0	0	0
2	S2	Derecha	1	S3	0	0	1	1	0.5
3	S3	Quedarse	3	S3	0	0	3	3	1.5
4	S3	Izquierda	5	S2	0	0.5	5.45	5.45	2.725
5	S2	Derecha	1	S3	0.5	2.725	3.4525	2.9525	1.9763
6	S3	Izquierda	5	S2	2.725	1.9763	6.7786	4.0536	4.7518

Conclusión

El valor Q más alto es **Q(S3, Izquierda) = 4.7518**. Significa que, con lo aprendido hasta ahora, la mejor decisión estando en S3 es ir a la izquierda: esa acción da +5 de inmediato y además conduce a S2, un estado desde el cual el agente ya descubrió que puede volver a S3 con recompensa (Q(S2,Derecha) = 1.9763). Es decir, un Q alto resume la **recompensa inmediata más el valor futuro descontado** de elegir esa acción.

Observa que el aprendizaje se **propaga hacia atrás**: en el paso 5, Q(S2,Derecha) saltó de 0.5 a 1.9763 porque el siguiente estado (S3) ya tenía un valor alto (2.725). Con una sola iteración los valores todavía son pequeños y están incompletos (Q(S1,·) sigue en 0); al repetir muchos episodios, Q converge a los valores óptimos de la Actividad 29 (por ejemplo Q*(S3,Izquierda) ≈ 31.05).

5. Actividad 28 · Diseña un agente y elige su algoritmo

Objetivo: seleccionar un algoritmo adecuado al problema.

Cómo se resuelve

Paso 1. Describe el agente y el entorno (aquí: un semáforo inteligente en un cruce).

Paso 2. Lista las **acciones**: pocas y discretas (mantener / cambiar fase).

Paso 3. Diseña la **recompensa**: penalizar la espera total de los autos y los cambios de fase excesivos.

Paso 4. Estima el **tamaño del espacio de estados**: si es enorme, descarta Q-learning tabular.

Paso 5. Compara las familias de algoritmos y elige la que encaja.

Paso 6. Justifica la elección con las características del problema.

Apartado	Descripción
Agente	Controlador inteligente de un semáforo en un cruce de dos avenidas.
Descripción del entorno	Un cruce simulado (por ejemplo en SUMO) con flujo de autos variable según la hora. El estado incluye la longitud de la fila en cada carril, el tiempo de espera acumulado y la fase actual del semáforo; es un espacio muy grande (valores continuos).
Acciones posibles	Mantener la fase actual o cambiar a la siguiente fase (verde para el otro sentido). Son pocas acciones discretas.
Recompensas esperadas	Recompensa = −(tiempo total de espera de los autos) en cada intervalo; −5 por cambios de fase demasiado frecuentes; +10 cuando se vacía una fila larga.
Tipo de algoritmo elegido	Basado en valores con aproximación por red neuronal: DQN (Deep Q-Network).
Justificación	Con filas de longitud variable el número de estados es enorme, y una tabla Q como la de la Actividad 27 no cabría en memoria. DQN conserva la lógica de Q-learning pero estima Q(s,a) con una red neuronal. Como las acciones son pocas y discretas, un método basado en valores encaja bien (los basados en políticas, como PPO, se justifican sobre todo con acciones continuas). Además usa repetición de experiencias para aprender de forma estable.

Comparación de algoritmos

Algoritmo	Familia	Ideal cuando…	¿Para este agente?
Q-learning tabular	Valores	Pocos estados y acciones discretas	No: el espacio de estados es demasiado grande
DQN	Valores + red neuronal	Muchos estados, acciones discretas	Sí: es la opción elegida
PPO / REINFORCE	Políticas	Acciones continuas o políticas estocásticas	Posible, pero más complejo de lo necesario
Dyna-Q	Basado en modelo	Simulaciones baratas y estados discretos	Útil si se aprende un modelo del tráfico, pero el modelo es difícil de ajustar

Código: por qué no basta una tabla Q, y cómo se calcula el objetivo de DQN

Primero se muestra el tamaño de la tabla Q si se discretiza el cruce; después, el objetivo que DQN calcula (igual que Q-learning, pero con una red que estima Q).

Código

```
import numpy as np
# --- 1) ¿Cabe una tabla Q? 4 carriles con filas de 0..30 autos, 4 fases, espera en 10 niveles
n_estados = (31 ** 4) * 4 * 10
print(f"Estados posibles: {n_estados:,}  x 2 acciones = {n_estados*2:,} celdas Q")

# --- 2) Recompensa del controlador
def recompensa_semaforo(espera_total, cambio_de_fase, fila_vaciada):
    return -espera_total - (5 if cambio_de_fase else 0) + (10 if fila_vaciada else 0)
print("r =", recompensa_semaforo(espera_total=12, cambio_de_fase=True, fila_vaciada=False))

# --- 3) Objetivo de DQN: y = r + gamma * max_a' Q_objetivo(s', a')  (con una red, aquí simulada)
gamma = 0.9
q_red_objetivo_siguiente = np.array([-14.2, -9.8])   # salida de la red para [mantener, cambiar]
r = recompensa_semaforo(12, True, False)
y = r + gamma * q_red_objetivo_siguiente.max()
print("Objetivo DQN y =", round(y, 2), " (la red se entrena para acercar Q(s,a) a y)")
```

Salida al ejecutarlo

```
Estados posibles: 36,940,840  x 2 acciones = 73,881,680 celdas Q
r = -17
Objetivo DQN y = -25.82  (la red se entrena para acercar Q(s,a) a y)
```

6. Actividad 29 · Calcula tu propia tabla Q

Objetivo: ver cómo cambiar una recompensa modifica los valores Q y la acción óptima.

Cómo se resuelve

Paso 1. Parte del mismo entorno de la Actividad 27.

Paso 2. Cambia la recompensa de (S3, Quedarse) de **+3 a +6**.

Paso 3. Recalcula Q con la **misma trayectoria** (una iteración) y compara con la original.

Paso 4. Calcula también los valores **óptimos Q*** repitiendo Bellman hasta converger, para ver la política final.

Paso 5. Compara las políticas y explica qué cambió y por qué.

Código

```
T3, T6 = construir_entorno(3), construir_entorno(6)      # original y modificado

# (1) Una iteración con la misma trayectoria
Q_orig, _ = simular_trayectoria(T3)
Q_new,  _ = simular_trayectoria(T6)
print("Tras una iteración (original +3):"); print(Q_orig.round(4))
print("\nTras una iteración (nueva +6):");   print(Q_new.round(4))

# (2) Valores óptimos Q*: repetir Q(s,a) = r + gamma * max Q(s',a') hasta converger
Qs3, Qs6 = q_optima(T3, gamma=0.9), q_optima(T6, gamma=0.9)
print("\nQ* original (+3):"); print(Qs3.round(2))
print("\nQ* nueva (+6):");   print(Qs6.round(2))
print("\nPolítica original:", politica(Qs3).to_dict())
print("Política nueva   :", politica(Qs6).to_dict())

# (3) Comprobación con Q-learning entrenado por interacción
Qe = entrenar_q_learning(T6, episodios=500)
print("\nPolítica aprendida por Q-learning:", politica(Qe).to_dict())
```

Salida al ejecutarlo

```
Tras una iteración (original +3):
    Izquierda  Derecha  Quedarse
S1     0.0000   0.0000       0.0
S2     0.0000   1.9762       0.0
S3     4.7518   0.0000       1.5

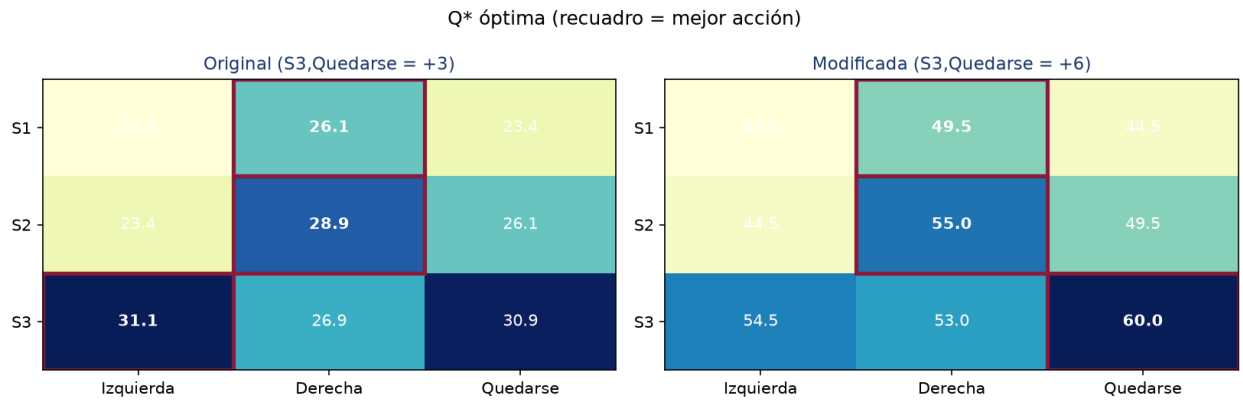
Tras una iteración (nueva +6):
    Izquierda  Derecha  Quedarse
S1     0.0000      0.0       0.0
S2     0.0000      2.1       0.0
S3     4.8075      0.0       3.0

Q* original (+3):
    Izquierda  Derecha  Quedarse
S1      22.45    26.05     23.45
S2      23.45    28.95     26.05
S3      31.05    26.95     30.95

Q* nueva (+6):
    Izquierda  Derecha  Quedarse
S1      43.55     49.5     44.55
S2      44.55     55.0     49.50
S3      54.50     53.0     60.00

Política original: {'S1': 'Derecha', 'S2': 'Derecha', 'S3': 'Izquierda'}
Política nueva   : {'S1': 'Derecha', 'S2': 'Derecha', 'S3': 'Quedarse'}

Política aprendida por Q-learning: {'S1': 'Derecha', 'S2': 'Derecha', 'S3': 'Quedarse'}
```



Análisis

¿Qué cambió en el comportamiento? En S3 la acción óptima pasó de **Izquierda** (Q* = 31.05 frente a 30.95 de Quedarse, casi empatadas) a **Quedarse** (Q* = 60 frente a 54.5). Antes al agente le convenía ir y venir entre S2 y S3 cobrando +5 y +1; ahora se queda en S3 cobrando +6 en cada paso. En S1 y S2 sigue yendo a la derecha, pero todos los valores Q suben porque llegar a S3 vale mucho más.

¿Por qué la nueva recompensa cambió la acción óptima? Porque el valor de una acción es la recompensa inmediata más el valor futuro descontado. Quedarse en S3 produce 6 + 0.9·V(S3), es decir V(S3) = 6/(1−0.9) = 60, mientras que el ciclo S3→S2→S3 rinde solo 5.9 por cada dos pasos (≈ 54.5). Al duplicar la recompensa de Quedarse, esa opción supera al ciclo. Tras una sola iteración la tabla todavía no lo refleja del todo, pero con el entrenamiento completo de Q-learning la política converge a la de la solución exacta.

7. Actividad 30 · Diseña tu propio agente y aplica la lógica del aprendizaje por refuerzo

Objetivo: comprender estado, acción, recompensa, política y valor diseñando un entorno propio.

Cómo se resuelve

Paso 1. Imagina un agente: un dron repartidor (**SkyBot**).

Paso 2. Escribe su propósito en un párrafo.

Paso 3. Completa la tabla: agente, entorno, estados, acciones, recompensas, política y evidencia de aprendizaje.

Paso 4. Indica qué **tipo de refuerzo** usa (positivo, negativo o ambos) y por qué.

Paso 5. Explica cómo **se adapta** con el tiempo (ε baja, Q se actualiza, la política converge).

SkyBot: dron repartidor que aprende a entregar paquetes

Propósito. SkyBot es un dron repartidor que debe entregar paquetes en un barrio sin conocer de antemano la mejor ruta. Por ensayo y error aprende a llegar al punto de entrega rápido, esquivar edificios y cables, y regresar a cargar antes de que se agote la batería.

Elemento	Diseño
Agente	SkyBot, dron repartidor
Medio ambiente	Barrio con edificios, cables, viento, una estación de carga y puntos de entrega
Posibles estados	Posición (x, y, altura), nivel de batería, si lleva paquete, distancia al destino
Acciones	Subir, bajar, avanzar en 4 direcciones, soltar paquete, volver a la estación
Recompensas o penalizaciones	+20 por entregar; +5 por cargar con batería baja; −1 por cada paso; −10 por chocar; −30 si cae por batería
Política (estrategia)	ε-greedy con Q(s,a): explora al inicio y después elige la acción de mayor valor; volver a cargar si la batería < 20 %
Cómo sabrás si aprendió correctamente	Entrega en pocos pasos de forma consistente, sin choques ni caídas, con retorno promedio estable y alto

Tipo de refuerzo y adaptación

SkyBot usa ambos tipos de refuerzo. El refuerzo positivo es el premio que se añade al entregar el paquete (+20) y al cargar la batería a tiempo; el refuerzo negativo aparece cuando llegar a la estación elimina el estado aversivo de batería baja, y además se aplican penalizaciones (−10 por chocar, −1 por paso) que desalientan conductas. Con el tiempo reduce la exploración (ε baja), actualiza sus valores Q con cada experiencia y su política converge hacia rutas más cortas, seguras y con recargas oportunas.

Código: recompensas y política ε-greedy de SkyBot

Código

```
import random
def recompensa_dron(entrego, choco, cayo, cargo_con_bateria_baja):
    r = -1                                  # cada paso gasta batería
    r += 20 if entrego else 0               # refuerzo POSITIVO: premio añadido
    r += 5 if cargo_con_bateria_baja else 0  # refuerzo NEGATIVO: desaparece la batería baja
    r -= 10 if choco else 0                 # penalización (castigo)
    r -= 30 if cayo else 0                  # penalización fuerte
    return r

def elegir_accion(Q_estado, acciones, epsilon):
    if random.random() < epsilon:           # explorar
        return random.choice(acciones)
    return max(acciones, key=lambda a: Q_estado[a])   # explotar: mayor Q

print("Entrega ........:", recompensa_dron(True, False, False, False))
print("Choca ..........:", recompensa_dron(False, True, False, False))
print("Carga a tiempo .:", recompensa_dron(False, False, False, True))
print("Cae sin batería :", recompensa_dron(False, False, True, False))

random.seed(0)
Q_estado = {"subir": 1.0, "avanzar": 4.5, "volver_a_cargar": 2.0}
for eps in (1.0, 0.5, 0.05):
    elecciones = [elegir_accion(Q_estado, list(Q_estado), eps) for _ in range(1000)]
    print(f"epsilon={eps:4}: elige 'avanzar' (la mejor) el {elecciones.count('avanzar')/10:.1f}% de las veces")
```

Salida al ejecutarlo

```
Entrega ........: 19
Choca ..........: -11
Carga a tiempo .: 4
Cae sin batería : -31
epsilon= 1.0: elige 'avanzar' (la mejor) el 32.4% de las veces
epsilon= 0.5: elige 'avanzar' (la mejor) el 68.5% de las veces
epsilon=0.05: elige 'avanzar' (la mejor) el 96.4% de las veces
```

Al bajar ε, SkyBot explota cada vez más lo aprendido: así se refleja que su comportamiento se adapta con el tiempo.